

哈爾濱Z業大學 (深圳) HARBIN INSTITUTE OF TECHNOLOGY

实验报告

井课学期:	2024	
课程名称:	大数据导论	
实验名称:		
实验性质:	设计型	
实验学时:		_
学生班级:	22级5班	
学生学号:	220110519	
学生姓名:	邢瑞龙	
评阅教师:		
报告成绩:		

实验与创新实践教育中心制 2024年9月

1. 实验目的

- 1. 熟悉 Hadoop 分布式集群的配置方法和基本操作;
- 2. 理解 MapReduce 的基本原理和框架;
- 3. 掌握 MapReduce 的基础编程方法,操作和运行 Mapreduce 作业。

2. 实验内容

- 1. 在大数据教学管理平台完成 Hadoop 完全分布式集群搭建;
- 2. 在 IntelliJ IDEA 中创建 MapReduce 工程,编码解决以下 3 个问题:
 - (1) 获取词频统计 Top 20 关键词
 - (2) 获取成绩表的最高分记录
 - (3) 统计网站每日的访问次数

3. 实验环境

- ✓ CentOS 7.9
- ✓ JDK 1.8
- ✓ Hadoop3.1.4
- ✓ IntelliJ IDEA 2022.2

4.实验过程及结果

4.1 Hadoop 集群环境搭建

Hadoop 分布式环境搭建过程中的关键步骤截图,如命令运行结果,修改后的配置文件 (使用 cat 命令查看)等。词频统计的结果文件需提交。

为 etc\profile 添加 java 的环境变量:

安装 JDK:

```
[root@slave2-0 ~] # cd /data
root@slave2-0 data|# rpm -ivh jdk-8u281-linux-x64.rpm
warning: jdk-8u281-linux-x64.rpm: Header V3 RSA/SHA256 Signature, key ID ec551f0
3: NOKEY
Preparing..
                                   ######### [100%]
Updating / installing...
1: jdk1.8-2000:1.8.0_281-fcs
                                   ######### [100%]
Unpacking JAR files...
       tools.jar...
       plugin.jar...
       javaws.jar...
       deploy.jar...
       rt.jar...
       jsse.jar...
       charsets.jar...
   localedata.jar...
```

修改 Hadoop 的配置文件: (图为 yarn-site. xml 实例):

修改 workers 文件:

```
[root@master-O hadoop] # cat workers
slave1
slave2
```

修改 HDFS 的启动脚本 start-dfs. sh 与停止脚本 stop-dfs. sh:

```
[root®master-0 sbin] # head -15 start-dfs.sh

#!/usr/bin/env bash

HDFS_DATANODE_USER=root

HDFS_DATANODE_SECURE_USER=root

HDFS_NAMENODE_USER=root

# Licensed to the Apache Software Foundation (ASF) under one or more

# contributor license agreements. See the NOTICE file distributed with

# this work for additional information regarding copyright ownership.

# The ASF licenses this file to You under the Apache License, Version 2.0

# (the "License"); you may not use this file except in compliance with
```

```
| TOOL@Master-O SDIN; # VI SCOP-UIS.SN
| root@master-O sbin] # head -15 stop-dfs.sh
| #!/usr/bin/env bash
| HDFS_DATANODE_USER=root
| HDFS_DATANODE_SECURE_USER=root
| HDFS_NAMENODE_USER=root
| HDFS_SECONDARYNAMENODE_USER=root
```

master 节点已经部署好的 Hadoop 与/etc/profile 文件复制传输到 slave1、slave2 节点:

3.3 MB/s	00:00
3.9 MB/s	00:00
3.8MB/s	00:00
3.1MB/s	
4.2MB/s	00:00
3.1MB/s	
285.9KB/s	00:00
3.5 MB/s	00:00
4.0MB/s	00:00
5.0MB/s	00:00
3.3 MB/s	00:00
2.4MB/s	00:00
3.0 MB/s	00:00
3.0 MB/s	00:00
3.7 MB/s	00:00
3.0 MB/s	00:00
4.1MB/s	00:00
5.8MB/s	00:00
5.7MB/s	00:00
6.5MB/s	00:00
8.1MB/s	00:00
6.3 MB /s	00:00
5.4MB/s	00:00

格式化成功:

```
[root@master-O sbin]# start-dfs.sh
■ Starting namenodes on [master]
■ 上一次登录: 三 9月 15 14:59:01 CST 2021
□ 最后一次失败的登录: 四 4月 14 10:35:36 CST 2022从 localhostssh:notty 上
□ 最有一次成功登录后有 1 次失败的登录尝试。
 master: Warning: Permanently added 'master,172.20.58.255' (ECDSA) to the list of known hosts.
 Starting datanodes
上一次登录:日 9月 29 17:21:08 CST 2024pts/0 上
slave1: WARNING: /usr/local/hadoop-3.1.4/logs does not exist. Creating.
gslave2: WARNING: /usr/local/hadoop-3.1.4/logs does not exist. Creating.
 Starting secondary namenodes [master]
上一次登录:日 9月 29 17:21:10 CST 2024pts/0 上
[roor⊜master-o spin]#
  [root@master-O sbin]# jps
 21077 NameNode
 21382 SecondaryNameNode
23687 JobHistoryServer
 23802 Jps
 23148 ResourceManager
[root@slave1-0 ~]# jps
389 Jps
534 NodeManager
429 DataNode
 Lust togin, sun sep 20 10
[root@slave2-0 ~]# jps
:401 DataNode
663 Jps
506 NodeManager
关闭集群:
```

```
[root®master-0 sbin] # stop-yarn.sh
Stopping nodemanagers
上一次登录:日 9月 29 17:24:55 CST 2024pts/0 上
Stopping resourcemanager
上一次登录:日 9月 29 1/2:27:41 CST 2024pts/0 上
```

[root@master-O sbin]# stop-dfs.sh Stopping namenodes on [master]

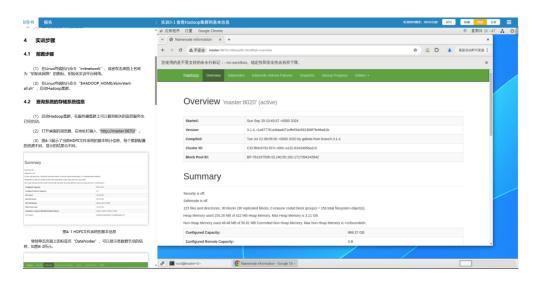
上一次登录:日 9月 29 17:27:44 **cs**T 2024**pts**/0 上

Stopping datanodes

上一次登录:日 9月 29 17:29:19 **csT** 2024**pts**/0 上

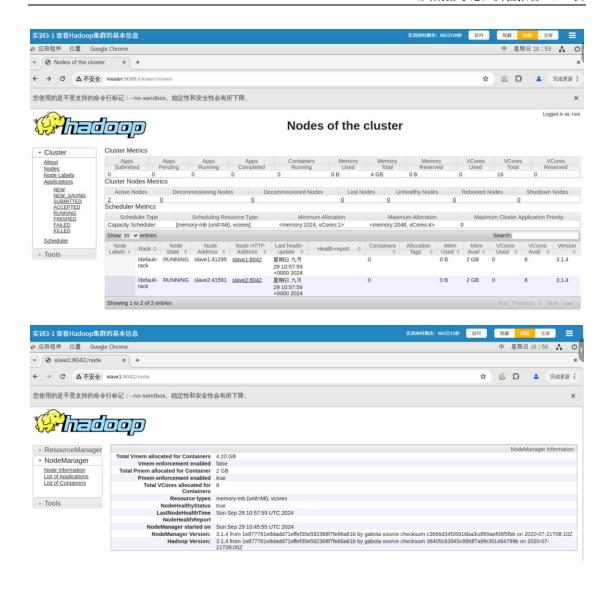
Stopping secondary namenodes [master] 上一次登录:日 9月 29 17:29:20 CST 2024pts/0 上

查看集群信息:



Security is off. 123 files and directories, 30 blocks (30 replicated blocks, 0 erasure coded block groups) = 153 total filesystem object(s), Heap Memory used 155.28 MB of 422 MB Heap Memory. Max Heap Memory is 3.11 GB. Non Heap Memory used 49.48 MB of 50.81 MB Committed Non Heap Memory. Max Non Heap Memory is <unbounded>. Configured Capacity: 889.37 GB Configured Remote Capacity: DFS Used: 3.05 MB (0%) Non DFS Used: 242.39 GB DFS Remaining: 646.98 GB (72.75%) DataNodes usages% (Min/Median/Max/stdDev): 0.00% / 0.00% / 0.00% / 0.00% Live Nodes 2 (Decommissioned: 0, In Maintenance: 0) Dead Nodes 0 (Decommissioned: 0, In Maintenance: 0) **Decommissioning Nodes** Entering Maintenance Nodes Total Datanode Volume Failures 0 (0 B) 0 Number of Blocks Pending Deletion (including replicas) Block Deletion Start Time Sun Sep 29 10:45:37 +0000 2024 Last Checkpoint Time Sun Sep 29 10:45:38 +0000 2024

查看 hadoop 节点的计算资源:



实训3-1 查看Hadoop集群的基本信息

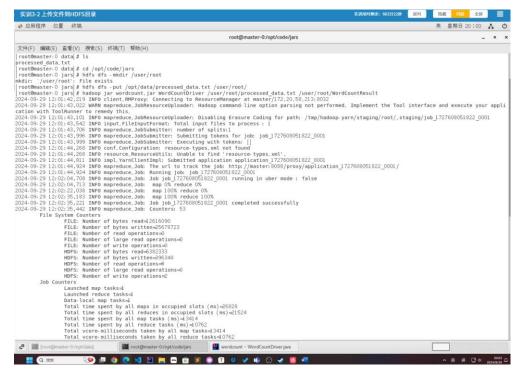
№ 应用程序 位置 终端

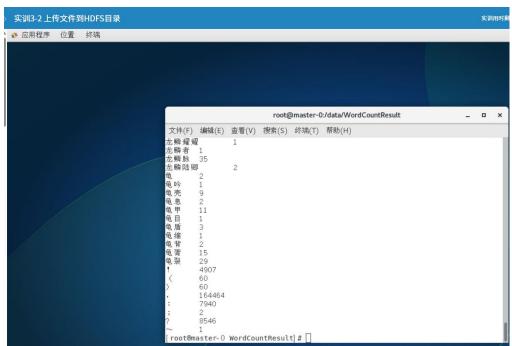
```
文件(F) 编辑(E) 查看(V) 搜索(S) 终端(T) 帮助(H)
Starting nodemanagers
上一次登录:日 9月 29 18:45:50 CST 2024pts/0 上
[root@master-0 ~] # hdfs dfsadmin - report
Configured Capacity: 954953998336 (889.37 GB)
Present Capacity: 694621978624 (646.92 GB)
DFS Remaining: 694618783744 (646.91 GB)
DFS Used: 3194880 (3.05 MB)
DFS Used%: 0.00%
Replicated Blocks:
        Under replicated blocks: 0
        Blocks with corrupt replicas: 0
       Missing blocks: 0
       Missing blocks (with replication factor 1): 0
       Low redundancy blocks with highest priority to recover: 0
       Pending deletion blocks: 0
Erasure Coded Block Groups:
       Low redundancy block groups: 0
       Block groups with corrupt internal blocks: 0
       Missing block groups: 0
       Low redundancy blocks with highest priority to recover: 0
       Pending deletion blocks: 0
Live datanodes (2):
Name: 172,20,85,202:9866 (slavel)
Hostname: slave1
Decommission Status: Normal
Configured Capacity: 477476999168 (444.69 GB)
DFS Used: 1597440 (1.52 MB)
Non DFS Used: 130166009856 (121.23 GB)
DFS Remaining: 347309391872 (323.46 GB)
DFS Used%: 0.00%
DFS Remaining%: 72.74%
Configured Cache Capacity: 0 (0 B)
Cache Used: 0 (0 B)
Cache Remaining: 0 (0 B)
Cache Used%: 100.00%
Cache Remaining%: 0.00%
Xceivers: 1
Last contact: Sun Sep 29 10:49:01 UTC 2024
Last Block Report: Sun Sep 29 10:45:46 UTC 2024
Num of Blocks: 30
```

4.2 MapReduce 编程

针对以下每个问题,简单描述你的 Mapper 和 Reducer 模块的处理逻辑,并截图部分 运行结果。每个项目 Mapper,Reducer 和 Driver 模块的代码文件(*.java)以及完整 的运行结果也需在作业平台提交。

统计词频:





(1) 获取词频统计 Top 20 关键词

Map 按行处理每个单词的出现次数。

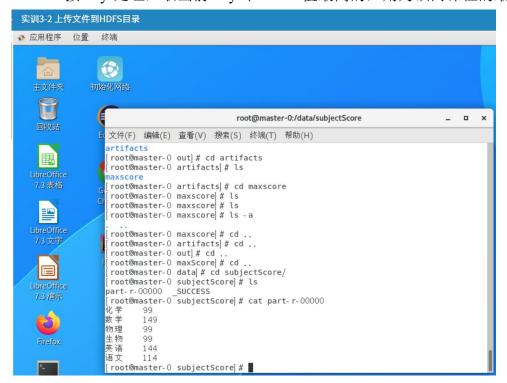
Reduce 按一个 key 一个 key 的来处理,以单词作为 key 值,汇总当个 key 对应的 所有 value 值求和便是该单词出现的总次数。

最后为了得到前 20 个词频最高的单词,在 reduce 中重写 clean_up,使用优先队列的方式,优先队列从头到尾词频依次递增。若当前队列长度>20,则弹出队首。



(2) 获取成绩表的最高分记录

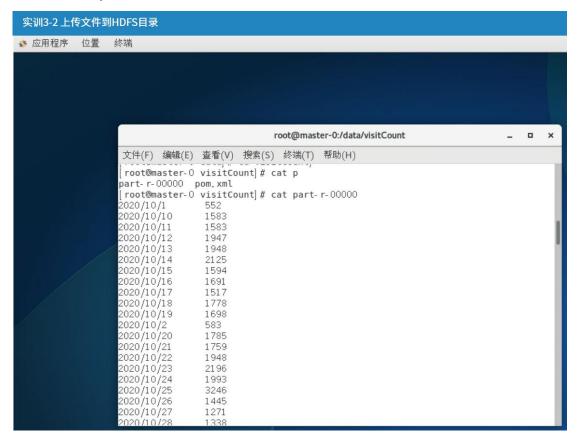
Map 按行处理,一次只处理一条记录,以课程作为 key,成绩为其 value。 Reduce 按 key 处理,取当前 key 中 value 值最高的,则为该门课程的最高成绩。



(3) 统计网站每日的访问次数

Map 按行处理,一次只处理一条记录,将第五列中的字符串以空格作为分隔符得到访问日期,将此作为 key, value 为 1 对应一次访问。

Reduce 按 key 处理,累计 value 出现的个数,便是当前日期对应的访问次数。



个人签名: 邢瑞龙

2024年 9月 29日